

Análisis Comparativo de Métodos de Optimización para una Función No Convexa

Kevin Alejandro Torres Perera
Grupo: C311

November 13, 2025

[Enlace al proyecto en GitHub](#)




Figure 1: Visualización 3D de la función objetivo.

Este informe presenta un análisis teórico y experimental del problema de minimización para la función no convexa $f(x,y) = 10(y - x^2)^2 + \frac{(x-1)^2}{2} + (y-1)^2$. El estudio tiene como objetivo caracterizar matemáticamente la función, determinar su mínimo teórico y, fundamentalmente, evaluar y comparar el rendimiento de dos algoritmos de optimización: el método de Newton con Gradiente Conjugado (Newton-CG) y el método quasi-Newton BFGS.

1 Análisis del Modelo

El problema consiste en la minimización sin restricciones de una función definida en R^2 . A continuación, se analiza la existencia de solución y la convexidad del modelo.

1.1 Existencia de Solución

La función objetivo es continua en todo su dominio. Además, es una función coercitiva, lo que significa que $f(x, y) \rightarrow \infty$ cuando la norma del vector (x, y) tiende a infinito. Esto se debe a los términos cuadráticos dominantes. Según el Teorema de Weierstrass, toda función continua y coercitiva sobre R^n alcanza un mínimo global. Por lo tanto, la existencia de al menos una solución para el problema de minimización está garantizada.

1.2 Convexidad

Como se detallará en el análisis de la matriz Hessiana, la función no es convexa globalmente. La falta de convexidad implica que los algoritmos de optimización podrían, en teoría, converger a mínimos locales en lugar del mínimo global. Sin embargo, para este problema particular, se demostrará que existe un único punto estacionario que corresponde al mínimo global, simplificando el desafío que la no convexidad podría presentar.

2 Caracterización de la Función Objetivo

La función objetivo a minimizar está definida en el dominio R^2 , ya que las operaciones que la componen —polinomios, sumas y productos— son válidas para cualquier par de números reales. Un análisis de sus términos revela que la función es no negativa en todo su dominio, dado que cada componente es un término cuadrático multiplicado por una constante positiva. La función alcanza su valor mínimo de cero si y solo si todos sus términos son simultáneamente nulos, lo cual ocurre únicamente en el punto $(1, 1)$. En cualquier otro punto, la función es estrictamente positiva.

La función es una composición de polinomios y combinaciones lineales, por lo que es continua en todo su dominio. Además, al ser un polinomio en las variables x e y , todas sus derivadas parciales de cualquier orden existen y son continuas. Esto implica que la función es infinitamente diferenciable, o suave (C^∞), lo que garantiza las condiciones de regularidad necesarias para aplicar métodos de optimización basados en el cálculo diferencial.

3 Gradiente y Matriz Hessiana

El gradiente de la función, $\nabla f(x, y)$, que indica la dirección de máximo crecimiento, se obtiene calculando las derivadas parciales con respecto a x e y . El resultado es el siguiente vector:

$$\nabla f(x, y) = \begin{bmatrix} 40x^3 - 40xy + x - 1 \\ 22y - 20x^2 - 2 \end{bmatrix}$$

La matriz Hessiana, $H(x, y)$, que describe la curvatura local de la función, se compone de las segundas derivadas parciales:

$$H(x, y) = \begin{bmatrix} 120x^2 - 40y + 1 & -40x \\ -40x & 22 \end{bmatrix}$$

El análisis de la Hessiana es crucial para entender la convexidad de la función. Una función es estrictamente convexa si su matriz Hessiana es definida positiva en todo su dominio. Sin embargo, en este caso, se puede demostrar que la función no es convexa globalmente. Por ejemplo, en el punto $(0, 1)$, el primer elemento de la diagonal de la Hessiana es negativo ($H_{11} = -39$) y su determinante también es negativo, lo que confirma que la matriz no es definida positiva. Esta no convexidad puede presentar desafíos para los algoritmos de optimización, aunque no impide la existencia de un mínimo global único.

4 Determinación del Mínimo Teórico

Para encontrar los candidatos a óptimos en un problema sin restricciones, se buscan los puntos estacionarios, es decir, aquellos donde el gradiente se anula. Al resolver el sistema de ecuaciones $\nabla f(x, y) = \mathbf{0}$, se encuentra que la función posee un único punto estacionario en $(1, 1)$.

Para clasificar este punto, se evalúa la matriz Hessiana en $(1, 1)$, resultando en:

$$H(1, 1) = \begin{bmatrix} 81 & -40 \\ -40 & 22 \end{bmatrix}$$

Esta matriz es definida positiva, ya que su primer elemento diagonal es positivo (81) y su determinante también lo es (182). Según el criterio de la segunda derivada, esto confirma que el punto (1, 1) es un mínimo local estricto. Dado que ya se ha establecido que $f(1, 1) = 0$ es el valor más bajo que la función puede tomar en todo su dominio, se concluye que (1, 1) es también el mínimo global único.

5 Descripción de los Algoritmos Evaluados

Para la minimización de la función objetivo, se seleccionaron dos algoritmos de optimización avanzados y ampliamente reconocidos, cada uno con un enfoque distinto para utilizar la información de la curvatura de la función.

5.1 Método de Newton-CG (Newton con Gradiente Conjugado)

El método de Newton-CG es una sofisticada variante del método de Newton clásico, diseñado específicamente para abordar problemas de optimización a gran escala donde el cálculo y la inversión de la matriz Hessiana son computacionalmente prohibitivos. El principio fundamental del método de Newton es aproximar la función objetivo con un modelo cuadrático en cada iteración y moverse hacia el mínimo de dicho modelo. Este paso es equivalente a resolver el sistema de ecuaciones lineales $H_k p_k = -\nabla f_k$, donde H_k es la matriz Hessiana y p_k es la dirección de búsqueda de Newton.

La innovación del Newton-CG radica en que, en lugar de invertir directamente la Hessiana, emplea el método del Gradiente Conjugado (CG) para resolver este sistema lineal de forma iterativa. El método CG es un algoritmo altamente eficiente para sistemas simétricos y definidos positivos. Este enfoque ofrece dos ventajas clave. Primero, en términos de eficiencia de memoria, evita la necesidad de formar o almacenar la matriz Hessiana completa, operando en su lugar con productos Hessiano-vector ($H_k v$) que a menudo pueden calcularse de manera mucho más eficiente. Segundo, su rapidez computacional le permite encontrar una solución aproximada de alta calidad para el sistema lineal sin necesidad de una solución exacta, lo cual se puede controlar mediante una tolerancia.

El algoritmo genera una secuencia de direcciones de búsqueda conjugadas, garantizando que la minimización del modelo cuadrático sea óptima en el subespacio explorado. Esto le permite aprovechar la información de la curvatura de segundo orden, lo que se traduce en una tasa de convergencia teóricamente cuadrática cerca del óptimo. Idealmente, esta rápida convergencia reduce significativamente el número de iteraciones necesarias en comparación con los métodos de primer orden. Sin embargo, su rendimiento depende críticamente de que la matriz Hessiana sea definida positiva, una condición que no siempre se cumple en funciones no convexas y que puede provocar fallos de convergencia.

5.2 Método Quasi-Newton BFGS

El método BFGS (Broyden-Fletcher-Goldfarb-Shanno) es uno de los algoritmos quasi-Newton más populares y efectivos. Su principal característica es que elude por completo el cálculo explícito de la matriz Hessiana. En su lugar, construye y actualiza iterativamente una aproximación de la Hessiana inversa (B_k^{-1}), utilizando únicamente información de primer orden: los gradientes.

El algoritmo comienza con una aproximación inicial de la Hessiana inversa (generalmente la matriz identidad) y la refina en cada paso. La actualización se realiza mediante una fórmula de bajo rango que satisface la "ecuación secante", asegurando que la nueva aproximación modele correctamente el comportamiento de la función a lo largo de la última iteración. La dirección de búsqueda se calcula de manera muy eficiente mediante un simple producto matriz-vector: $p_k = -B_k^{-1} \nabla f_k$.

Las principales ventajas del método BFGS son su bajo costo computacional, ya que al evitar el cálculo de segundas derivadas, cada iteración es significativamente más ligera que en el método de Newton. Además, destaca por su robustez, pues la fórmula de actualización está diseñada para mantener la aproximación de la Hessiana definida positiva, lo que hace al método más estable y robusto, especialmente en regiones no convexas. Finalmente, presenta una buena convergencia, con una tasa superlineal que, aunque teóricamente más lenta que la de Newton, es muy rápida en la práctica y a menudo supera a Newton-CG en tiempo total de ejecución.

Gracias a este equilibrio entre eficiencia y robustez, BFGS es frecuentemente el método de elección para una amplia gama de problemas de optimización no lineales sin restricciones.

Ambos algoritmos fueron implementados en este proyecto utilizando la función `scipy.optimize.minimize` de la biblioteca SciPy en Python. Esta función proporciona una interfaz unificada para una amplia gama de algoritmos de optimización. Para invocar los métodos específicos, se pasó el nombre del algoritmo ('Newton-CG' o 'BFGS') en el parámetro `method`. Puede encontrar más detalles en la documentación oficial de SciPy.

6 Análisis de Resultados Experimentales

Para evaluar el rendimiento práctico de ambos algoritmos, se ejecutó un conjunto de 34 experimentos combinando diferentes puntos iniciales y tolerancias. El análisis se centra en tres métricas clave: la eficiencia (tiempo de ejecución), la precisión (distancia a la solución óptima) y la velocidad de convergencia (número de iteraciones).

6.1 Eficiencia Computacional

La eficiencia, medida como el tiempo total de ejecución, es una de las comparativas más directas del rendimiento. Como se observa en la Figura 2, el método BFGS es consistentemente más rápido que Newton-CG en la gran mayoría de las configuraciones.




Figure 2: Comparación del tiempo de ejecución (en segundos) entre Newton-CG y BFGS para todas las configuraciones experimentales. Un valor menor indica mayor eficiencia.

Aunque la teoría sugiere que los métodos de Newton pueden converger en menos pasos, su coste por iteración es significativamente mayor debido al cálculo y manejo de la matriz Hessiana. En contraste, BFGS, al aproximar esta información, mantiene un coste computacional por iteración mucho más bajo, lo que le otorga una ventaja decisiva en velocidad para este problema.

6.2 Precisión y Calidad de la Solución

La precisión se evaluó midiendo la distancia euclidiana entre la solución encontrada por el algoritmo y el mínimo teórico conocido (1,1). La Figura 3 muestra que ambos métodos son capaces de encontrar soluciones de muy alta precisión, con distancias al óptimo del orden de 10^{-6} o inferiores.

Si bien no hay un ganador absoluto en términos de precisión, lo más destacable es la robustez del método BFGS. A lo largo de todos los experimentos, BFGS convergió exitosamente. En cambio, Newton-CG falló en varias configuraciones (indicado por barras de altura cero en algunas gráficas o valores anómalos), especialmente con puntos iniciales alejados del óptimo. Los registros de los experimentos (`results_exp1.json` y `results_exp2.json`) confirman esto con advertencias como **Warning: CG iterations didn't converge. The Hessian is not positive definite**. Esto sucede porque la no convexidad de la función en ciertas regiones del dominio impide que el subproblema del gradiente conjugado se resuelva adecuadamente.




Figure 3: Comparación de la distancia a la solución óptima. La escala logarítmica en el eje Y resalta las pequeñas diferencias en precisión. Un valor menor es mejor.

6.3 Velocidad de Convergencia

El número de iteraciones, mostrado en la Figura 4, ofrece una visión más profunda del comportamiento de convergencia. Contrario a lo que se podría esperar, Newton-CG no siempre converge en menos iteraciones que BFGS. En muchos casos, ambos métodos requieren un número similar de pasos.




Figure 4: Comparación del número de iteraciones requeridas para la convergencia.

Este resultado, combinado con el análisis de eficiencia, refuerza la conclusión de que el menor coste por iteración de BFGS es el factor determinante de su superioridad en el rendimiento global. La capacidad de BFGS para realizar más iteraciones en menos tiempo lo convierte en una opción más pragmática y eficiente para este problema.

7 Conclusiones Finales

El análisis comparativo entre Newton-CG y BFGS para la minimización de esta función no convexa arroja conclusiones claras y de gran relevancia práctica.

Primero, la robustez es un factor crítico. El método BFGS demostró ser significativamente más robusto, garantizando la convergencia desde todos los puntos iniciales probados. La dependencia de Newton-CG de una matriz Hessiana definida positiva lo vuelve vulnerable en paisajes de optimización complejos como el estudiado.

Segundo, la eficiencia teórica no siempre se traduce en un mejor rendimiento práctico. Como demuestran las Figuras 2 y 4, el menor costo por iteración de BFGS resultó en una mayor eficiencia global, superando a Newton-CG en tiempo de ejecución en la mayoría de los experimentos, incluso cuando el número de iteraciones era comparable.

Finalmente, en cuanto a la precisión (Figura 3), ambos métodos son capaces de alcanzar una alta exactitud, pero la fiabilidad de BFGS para lograrlo en el 100% de los casos lo consolida como el método más predecible y seguro.

En definitiva, para el problema estudiado, el algoritmo BFGS ofrece el mejor compromiso entre velocidad, precisión y, fundamentalmente, robustez. Su enfoque de aproximar la información de segundo orden le confiere la flexibilidad necesaria para navegar por el dominio no convexo de manera eficaz y fiable. Por lo tanto, se concluye que BFGS es la elección pragmática y superior para esta clase de problemas de optimización.